Do Simbólico à Incerteza: Análise do Atraso na Notificação Vacinal do PNI com Inteligência Artificial

Bruna Brasil[1], **Jamily Oliveira**[1], **Luiz Sena**[1], **Roberta Brasil**[1]

[1]Departamento de Ciência da Computação – Universidade Federal do Amazonas (UFAM)
Manaus – AM – Brasil

{bruna.brasil, jamily.oliveira, luiz.sena, roberta.brasil}@icomp.ufam.edu.br

1. Introdução

A vigilância epidemiológica depende da integridade e continuidade dos registros vacinais. No Brasil, o Programa Nacional de Imunizações (PNI), sob gestão do Ministério da Saúde e do DATASUS, organiza imunizações em escala nacional através da Rede Nacional de Dados em Saúde (RNDS). Diferenças nas condições de registro e conectividade das unidades podem estar associadas ao intervalo entre a aplicação e a inserção dos dados no sistema central.

Notificações tardias podem comprometer a atualização das estimativas de cobertura vacinal e dificultar o monitoramento epidemiológico. A questão investigada neste trabalho é: *Quais características se associam ao tempo de notificação vacinal?*

Partiu-se de 16.000 registros extraídos da API de Dados Abertos do Ministério da Saúde (4.000 por ano, entre 2023 e 2026). Após a remoção de dados inválidos, restaram $N = 15.403$ registros. Trata-se de uma amostra exploratória. No código, `sistema_offline`=1 indica que a descrição do sistema de origem contém "OFFLINE"; o valor 0 identifica os demais sistemas, não necessariamente conexão contínua. A latência contínua é definida por $\Delta t = \text{dt_entrada} - \text{dt_vacina}$, expressa como `dias_atraso`. A partir dela, formulou-se a variável-alvo binária primordial:

$$Y = \begin{cases} 1, & \text{se } \Delta t > 7 \text{ dias}, \\ 0, & \text{se } 0 \leq \Delta t \leq 7 \text{ dias}. \end{cases} \tag{1}$$

Na base analisada, há 7.947 ocorrências de atraso crítico ($51{,}59\%$) e 7.456 no prazo ($48{,}41\%$), configurando um cenário amostral equilibrado para a modelagem.

2. Organização do Trabalho

O trabalho foi dividido em seis etapas: (1) árvore de decisão; (2) regressões linear e logística; (3) teoria da probabilidade; (4) MLE, MAP, Naive Bayes e EM; (5) Redes Bayesianas; e (6) lógica fuzzy. As etapas utilizam a mesma base e avançam da identificação de padrões para a modelagem probabilística e o apoio gradual à decisão.

3. Etapa 1 – Árvore de Decisão

A primeira etapa utilizou uma implementação de árvore de decisão para prever `atraso_critico`, definido como uma notificação realizada mais de sete dias após a

vacinação. A seleção dos atributos foi feita por entropia e ganho de informação:

$$H(S) = -\sum_{c} p_c \log_2(p_c), \tag{2}$$

$$IG(S,X) = H(S) - \sum_{v} \frac{|S_v|}{|S|} H(S_v). \tag{3}$$

No primeiro ciclo, a entropia foi de $0{,}9993$ bits. O atributo `sistema_offline` apresentou o maior ganho de informação ($0{,}2133$ bits), acima de fabricante ($0{,}0441$), faixa etária ($0{,}0378$), mesmo município ($0{,}0360$) e região ($0{,}0177$). Entre os registros classificados como offline, 77,43% apresentaram atraso; nos demais sistemas, a proporção foi de 24,44%.

A árvore foi avaliada por validação cruzada com 5 dobras e obteve acurácia média de **76,53%**, com F1 médio de 77,47%. A etapa também demonstrou, por meio de um exemplo simulado, a não-monotonicidade do aprendizado indutivo: ao adicionar novos exemplos, a árvore pode alterar uma regra ou classificação anteriormente aprendida, diferentemente do comportamento monotônico da Lógica de Primeira Ordem.

4. Etapa 2 – Aprendizado Linear

A segunda etapa modelou o atraso contínuo por $y = \ln(1 + \texttt{dias_atraso})$. Na regressão linear univariada por mínimos quadrados, obteve-se:

$$\hat{y} = 2{,}2492 + 0{,}7772x, \tag{4}$$

com $R^2 = 0{,}2781$ e MSE de $1{,}7470$ no teste. A regressão multivariada por gradiente descendente elevou o R^2 para $0{,}3015$, com MSE de $1{,}6904$.

Também foi testada regularização Ridge. Entretanto, algumas execuções apresentaram *overflow* e valores `NaN`, portanto o material atual não permite afirmar um λ ótimo confiável. Para a classificação binária, a regressão logística implementada por gradiente alcançou **77,47% de acurácia**, 78,25% de precisão, 78,05% de recall e 78,15% de F1.

5. Etapa 3 – Teoria da Probabilidade

A distribuição conjunta entre origem do sistema (S) e atraso crítico (A) foi calculada e validada, com soma das probabilidades igual a 1. As principais probabilidades foram:

$$P(A = 1 \mid S = 0) = 0{,}2444, \tag{5}$$

$$P(A = 1 \mid S = 1) = 0{,}7743. \tag{6}$$

Assim, na amostra, a proporção de atraso no grupo offline foi aproximadamente $3{,}17$ vezes a observada nos demais sistemas. Pelo Teorema de Bayes:

$$P(S = 1 \mid A = 1) = \frac{0{,}7743 \cdot 0{,}5125}{0{,}5159} \approx \mathbf{0{,}7691}. \tag{7}$$

Logo, 76,91% dos registros atrasados pertenciam ao grupo classificado como offline.

Também foi verificada a hipótese de independência condicional usada pelo Naive Bayes. Para fabricante Pfizer e faixa etária idoso, condicionados ao atraso, foram obtidos $P(X,Y \mid A) = 0{,}01422$ e $P(X \mid A)P(Y \mid A) = 0{,}00392$. Como os valores diferem de 0,06, esse teste apresentou uma grande chance de independência condicional.

6. Etapa 4 – MLE, MAP, Naive Bayes e EM

No conjunto de treino, com $n = 12.322$ e $k = 6.357$ atrasos, as estimativas MLE e MAP com prior $\mathrm{Beta}(2,2)$ foram praticamente iguais:

$$\hat{\theta}_{\mathrm{MLE}} = \frac{6.357}{12.322} = 0{,}51591, \tag{8}$$

$$\hat{\theta}_{\mathrm{MAP}} = \frac{6.358}{12.324} = 0{,}51590. \tag{9}$$

A diferença pequena ocorre pelo grande volume de dados; em amostras reduzidas, o MAP evita estimativas extremas e o MLE varia bastante entre 0% a 100%. O Naive Bayes obteve **75,79% de acurácia** e F1 de 75,70%.

Em seguida, o algoritmo EM foi aplicado a $x = \ln(1 + \texttt{dias_atraso})$ com uma mistura de duas gaussianas. Após 30 iterações, foram identificadas duas componentes estatísticas: uma de menor atraso, com peso $0{,}421$ e média aproximada de 0,9 dia, e outra de maior atraso, com peso $0{,}579$ e média aproximada de 29,1 dias. Ao adicionar a componente latente Z ao Naive Bayes, a acurácia registrada subiu para 93,77%.

7. Etapa 5 – Redes Bayesianas

A Rede Bayesiana foi construída com cinco variáveis binárias: região (R), origem do sistema (S), grupo vulnerável (V), fabricante (N) e atraso crítico (A). O DAG proposto utiliza as relações $R \to S$, $S \to A$, $V \to N$ e $N \to A$, resultando na fatoração:

$$P(R,S,V,N,A) = P(R)P(S \mid R)P(V)P(N \mid V)P(A \mid S,N). \tag{10}$$

Essas arestas representam hipóteses de modelagem, não relações causais comprovadas pelos dados.

A rede contém a cadeia $R \to S \to A$ e o colisor $S \to A \leftarrow N$. Na inferência por enumeração, obteve-se $P(A = 1 \mid S = 1,N = 1) = 0{,}7458$, valor confirmado com o pacote `pgmpy`. A principal vantagem da estrutura foi a redução de parâmetros: uma distribuição conjunta completa com cinco variáveis binárias exigiria 31 parâmetros livres, enquanto o DAG proposto utiliza apenas 10, uma redução de **67,74%**.

8. Etapa 6 – Lógica Fuzzy

A última etapa transforma o risco probabilístico em uma prioridade gradual de acompanhamento. Foi implementado um sistema Fuzzy Mamdani com duas entradas: o risco bayesiano $r = P(A = 1 \mid \mathbf{e})$ e uma vulnerabilidade v de 0 a 100. A saída é a urgência u, também de 0 a 100. Cada variável possui conjuntos linguísticos baixo, médio e alto, permitindo que um valor tenha diferentes graus de pertinência ao mesmo tempo.

Foram implementadas cinco regras. Em resumo, risco e vulnerabilidade altos geram urgência alta; risco médio gera urgência média; risco baixo tende a gerar urgência baixa, exceto quando combinado com vulnerabilidade alta. A saída final é calculada pelo método do centróide:

$$u^* = \frac{\int u\,\mu(u)\,du}{\int \mu(u)\,du}. \tag{11}$$

A integração foi testada em três **cenários ilustrativos**, e não em unidades reais identificadas:

Tabela 1. Resultados dos cenários utilizados na etapa fuzzy.

Cenário	Risco	Vulnerabilidade	Urgência
Posto rural remoto	74,58%	85%	**64,61**
Unidade urbana central	30,59%	30%	**38,79**
Unidade de fronteira	17,58%	65%	**23,90**

Diferentemente de um limiar rígido, a lógica fuzzy permite transições graduais entre níveis de prioridade. Nesse trabalho, ela funciona como uma camada de apoio à decisão sobre as probabilidades produzidas nas etapas anteriores, sem representar uma intervenção real já validada no SUS.

9. Considerações Finais

As seis etapas permitiram analisar o atraso de notificação vacinal sob diferentes perspectivas. A árvore de decisão destacou `sistema_offline` como o atributo de maior ganho de informação e obteve 76,53% de acurácia média. A regressão logística alcançou 77,47%, enquanto o Naive Bayes puro obteve 75,79%. A análise probabilística mostrou maior proporção de atrasos no grupo offline, e a Rede Bayesiana reduziu a parametrização de 31 para 10 valores. O EM identificou dois componentes de atraso, elevando a acurácia para 93,77%. Por fim, a lógica fuzzy integrou risco e vulnerabilidade em escores graduais de urgência. Assim, o trabalho demonstra a integração entre técnicas simbólicas, estatísticas, probabilísticas e fuzzy, preservando as limitações dos experimentos realizados.

A. Metodologia, Reprodutibilidade e Uso de IA

Os notebooks das seis etapas e os módulos Python estão disponíveis no repositório do grupo (`https://github.com/Gabsz193/saude_publica_equipe_2`). O projeto utiliza bibliotecas como `numpy`, `pandas`, `scikit-learn`, `pgmpy` e `scikit-fuzzy`; as instruções de execução constam no `README.md`. Foi adotada semente aleatória fixa nas etapas que envolvem amostragem ou inicialização.

Registro do uso de IA: houve auxílio de ferramentas de IA na elaboração de código, conforme informado pela equipe.

Em conformidade com as diretrizes éticas e recomendações da disciplina sobre o uso responsável de modelos de linguagem de grande porte (LLMs), esses são os (*prompts*) submetidos ao assistente ao longo das fases de concepção, codificação e validação empírica.

> *"Quero que analise o propósito do trabalho e utilize as melhores práticas em python e análise de dados exploratória para entender a API do trabalho e como poder extrair suas informações. No reposório, há as especificações do trabalho de fundamentos de IA, minha equipe escolheu essa API para extrair os dados do site https://apidadosabertos.saude.gov.br/v1 da rota Vacinacao/get_vacinacao_doses_aplicadas_pni_2020 de 2020 até 2026. Se forem muitos dados, reduza para os anos mais atuais. Dê uma olhada no trabalho, faça*

um plano de implementação e me diga no final o que você irá fazer. Pode analisar a API e os dados para ter uma ideia do que ser feito. O domínio do nosso projeto é "Saúde Pública". Para ler o documento pdf, sugiro fazer um markdown dele para consultá-lo"

"Me fale dos resultados que encontrou que são interessantes para a conclusão. Primeiro fala de cada etapa. Então faça uma conclusão reunindo todas as evidências de todas as etapas."

"Quantas amostras foram usadas? Para treinamento e teste? Em relação às regiões? Ficou bem dividido?"

"O que você quis dizer com validação da independência condicional e limitação da lógica clássica?"

"Mas por que apenas o dado de Pfizer e Idoso? Não deveria ser de vários?"

"Explique melhor essa etapa 4. O que ela significa? O que é prior conjugada de Beta(2,2)? O que isso significa na prática?"

"Por que o fabricante influencia se vai atrasar?"

"Explique a etapa 6 e o que a tarefa pedia."